

Faculté des Sciences et Ingénierie - Sorbonne université

Master Informatique - parcours DAC



Dalas : Datascience, learning and applications

Rapport de Projet

Étude sur les offres d'hébergement de Booking.com

Réalisé par :

Yacine B. D. Chettab

Carine Moubarak

Supervisé par :

Laure Soulier

24 Mai 2024

Table des matières

Introduction	1
1 Collecte des données	2
1.1 Sources de données utilisées	2
1.2 Méthodologie de collecte des données	3
1.2.1 Collecte de données pour Booking.com	3
1.2.2 Collecte de données pour Numbeo	3
1.2.3 Collecte de données pour les autres sites	3
1.2.4 Fonctions réalisées pour la collecte des données	3
1.3 Description des données sur les offres d'hébergement	4
1.4 Description des données sur l'environnement local	5
1.5 Processus de nettoyage et de prétraitement des données	7
2 Analyses et visualisation de données	8
2.1 Description de l'ensemble des données	8
2.2 Distribution des données	9
2.2.1 Les pays étudiés	9
2.2.2 Répartition des pays étudiés par continent	10
2.2.3 Distribution du score, du nombre d'étoiles et de la distance par rapport au centre-ville	10
2.2.4 Distribution du type d'annulation et des services de petit-déjeuner proposés	10
2.3 Les relations entre les variables	13
2.3.1 Relation entre le prix et le score	13
2.3.2 Relation entre la distance du centre-ville et le score	14
2.3.3 La corrélation	16
2.4 Analyse en Composantes Principales	17
3 Modèles de prédiction	18
3.1 Prédiction du score à partir des variables des villes	18
3.2 Prédiction du continent à partir des variables des hôtels	19
3.3 Prédiction de la région à partir des variables des hôtels	20
3.4 Prédiction du pays et la ville d'un hôtel	21
4 Tableau de bord	22

Introduction

Dans le cadre de ce projet, nous avons entrepris une analyse approfondie des données extraites du site Booking.com et d'autres sources, portant sur les offres d'hébergement disponibles en ligne, ainsi que sur les données relatives à leur environnement. L'objectif principal de cette analyse est de comprendre les dynamiques du marché hôtelier à travers différentes dimensions telles que les prix, les évaluations, le volume de rétroaction, le niveau de vie local et la démographie. Ces informations revêtent une importance cruciale pour les acteurs de l'industrie hôtelière, les décideurs politiques et les chercheurs, dans leur quête d'optimisation des stratégies commerciales, d'amélioration de la satisfaction client et de compréhension des tendances touristiques.

Face à un marché hôtelier en constante évolution, il est crucial de comprendre les facteurs qui influent sur la performance des hôtels. Comment les prix des hôtels sont-ils liés à leurs évaluations ? Dans quelle mesure le volume de rétroaction affecte-t-il la satisfaction client ? Comment le niveau de vie local influence-t-il l'accessibilité des hôtels ? Ces questions guideront notre analyse et nous permettront d'extraire des insights pertinents pour les parties prenantes.

Collecte des données

La collecte des données constitue le point de départ essentiel de notre étude. Dans ce chapitre, nous détaillerons les différentes sources de données que nous avons exploitées, ainsi que la méthodologie utilisée pour les collecter. Les données ont été collectées en utilisant des outils et des techniques de programmation, en Python, avec l'aide de bibliothèques telles que *Beautiful Soup* pour le web scraping. Cette approche nous a permis de rassembler des informations détaillées sur les offres d'hébergement disponibles ainsi que sur l'environnement local dans diverses destinations. Nous commencerons par présenter les sources de données que nous avons utilisées, en soulignant l'importance de chacune dans notre étude. Ensuite, nous décrirons en détail la méthodologie de collecte des données pour chaque source, en mettant en lumière les défis rencontrés et les solutions mises en place pour les surmonter.

1.1 Sources de données utilisées

Les données utilisées dans ce projet proviennent de différentes sources, collectées à l'aide d'un code Python. Voici les sources utilisées :

- **Booking.com**¹ est une source essentielle pour les données sur les hôtels, fournissant des détails sur les prix, les évaluations et la disponibilité des hébergements pour une date spécifique. Pour les besoins de notre étude, nous avons fixé une date d'arrivée au 16/11/2024 et une date de départ au 17/11/2024 pour 1 adulte.
- **Numbeo**² est utilisé pour collecter des données sur le coût de la vie et le contexte économique de chaque ville. Cette plateforme fournit des données sur les prix par ville et par pays, répartis en régions géographiques.
- **Worldometer**³ fournit des données générales sur les pays et leur population.
- **World Population Review**⁴ est une source des données sur les arrivées annuelles de touristes internationaux.
- **SimpleMaps** propose des données téléchargeables sur la population des villes⁵.

1. <https://www.booking.com/>

2. https://www.numbeo.com/cost-of-living/prices_by_city.jsp

3. <https://www.worldometers.info/world-population/>

4. <https://worldpopulationreview.com/country-rankings/most-visited-countries>

5. https://simplemaps.com/data/world-cities#anchor_updates

1.2 Méthodologie de collecte des données

1.2.1 Collecte de données pour Booking.com

Le processus de collecte de données pour *Booking.com* implique deux phases distinctes. Tout d'abord, le crawling est effectué pour récupérer les liens associés aux offres d'hébergement de chaque hôtel, accessibles via des URLs spécifiques. Ces dernières sont obtenues en lançant une requête dans le moteur de recherche de *Booking.com* pour une date d'arrivée fixée au 16/11/2024 et une date de départ au 17/11/2024 pour 1 adulte. Ensuite, dans la deuxième phase, les données sont collectées en accédant aux URLs.

Dans la première phase, nous collectons également des données sur l'hôtel, tandis que dans la deuxième phase, nous récupérons des informations spécifiques sur les chambres d'hôtel ou les offres d'hébergement. Il convient de noter que certains attributs, tels que les évaluations du personnel et des installations, sont omis lors de la collecte des données des chambres et seront traités ultérieurement au niveau supérieur, concernant les établissements hôteliers dans leur ensemble.

1.2.2 Collecte de données pour Numbeo

La collecte de données pour Numbeo présente une particularité significative : chaque caractéristique ou variable que nous souhaitons collecter est répartie par régions géographiques. Ainsi, sur le site, il est nécessaire de choisir d'abord une variable, puis de préciser la région géographique qui nous intéresse dans la page suivante.

Dans ce contexte, une première phase de crawling s'avère nécessaire pour récupérer les liens lors du scraping de la première variable. Cette étape nous permet d'obtenir les identifiants de chaque région géographique et de chaque variable, qui sont ensuite utilisés dans les URL. Par la suite, pour les autres variables, il suffit de générer les liens à partir de ces identifiants et de scraper les tableaux de données sur chaque page associée à ces URL.

1.2.3 Collecte de données pour les autres sites

En revanche, pour les deux autres sites, il n'est pas nécessaire d'effectuer une phase de crawling distincte. Le scraping est directement réalisé à l'aide de Beautiful Soup, et les données sont ensuite sauvegardées dans des DataFrames avant d'être exportées au format CSV.

1.2.4 Fonctions réalisées pour la collecte des données

Ces fonctions, situées dans le fichier `1_scrap.ipynb`, jouent un rôle essentiel dans le processus de collecte des données, en automatisant les tâches de crawling et de scraping pour obtenir des informations pertinentes à partir des sites Web sélectionnés.




FIGURE 1.1 – Temps d'exécution de la partie collecte de données.

1. **scrap_cities_data** collecte les données sur le site *Numbeo*, notamment les prix des différentes variables par ville.
2. **scrap_regions** récupère les identifiants de chaque région et continent à partir du site *Numbeo*, nécessaires pour construire les URLs spécifiques d'accès aux données de chaque variable par région.
3. **create_nested_dict** crée une structure de données illustrant la relation hiérarchique entre les villes, les pays, les régions et les continents, facilitant ainsi l'organisation des données par région géographique.
4. **scrap_cities** récupère, en utilisant les identifiants collectés précédemment, les données sur les villes à partir du site *Numbeo* et les sauvegarde dans un fichier CSV.
5. **crawl_hotel_links** collecte les liens des offres d'hébergement sur le site *Booking.com* en lançant des requêtes spécifiques avec les paramètres de date d'arrivée et de départ.
6. **scrap_hotels_data** extrait, une fois les liens des hôtels collectés, les données spécifiques sur les chambres, les tarifs, les services et les évaluations de chaque hôtel sur *Booking.com*, et les sauvegarde dans des fichiers CSV organisés par région géographique.

La figure 1.1 illustre le temps total du scrapping par région géographique.

1.3 Description des données sur les offres d'hébergement

Les fichiers sous le format **links/hotels_c_cn_r_rn.csv**, où *c* représente le nom du continent, *cn* représente le numéro du continent, *r* représente la région et *rn* représente le numéro de la région, fournissent des données spécifiques sur les hôtels dans différentes régions géographiques. Chaque fichier est associé à une région particulière, telles que *Caribbean*, *Central America*, *Central Asia*, *Eastern Africa*, *Eastern Asia*, *Eastern Europe*, *Northern Africa*, *Northern America*, *Northern Europe*, *Oceania*, *South America*, *South-Eastern Asia*, *Southern Africa*, *Southern Asia*, *Southern Europe*, *Western Africa*, *Western*

Asia, et *Western Europe*. Ces fichiers comprennent les informations suivantes pour chaque hôtel :

- Un lien URL vers la page de réservation, qui sert comme un identifiant.
- Le nom de l'établissement.
- La ville et le pays où il est situé.
- L'emplacement géographique (comme une adresse postale).
- Les notations, le score et le nombre de critiques.
- La distance du centre-ville en kilomètres.
- Le nombre d'étoiles, si l'hôtel est étoilé.

Les fichiers sous le format **data_hotels_nomRegion.csv** fournissent des données spécifiques sur les offres d'hébergement dans différentes régions géographiques. Chaque fichier est associé à une région particulière. Ces fichiers représentent chaque type de chambre disponible dans chaque hôtel existant dans le répertoire */links* au moment du scraping. Ces fichiers comprennent les informations suivantes pour chaque offre d'hébergement :

- Un lien URL vers la page de réservation, qui sert à faire le lien avec les fichiers dans */links*.
- Le type de chambre disponible, tel que "Economic Single Room" ou "Standard Double Room", par exemple.
- Le nombre de personnes pouvant être hébergées dans la chambre.
- Le prix de la chambre en euros.
- La disponibilité du petit-déjeuner (valeur de -1 si l'établissement ne propose aucun service de petit-déjeuner, 0 si ceci est offert gratuitement, sinon la valeur est le prix en euros).
- Les conditions d'annulation (1 si l'annulation est gratuite sous conditions et 0 si la réservation est non-remboursable).

1.4 Description des données sur l'environnement local

Le fichier **cities.csv** fournit des données sur différentes villes à travers le monde. Il est de 388 lignes et 73 colonnes. Il comprend les colonnes suivantes :

- Le nom de la ville concernée.
- Le pays, la région et le continent où se trouve la ville.
- Données économiques et de coût de la vie : Cette section comprend diverses informations économiques et de coût de la vie (en euro) pour chaque ville, telles que :
 - Prix des appartements à l'extérieur et dans le centre-ville.

- Coûts de l'éducation pour les enfants.
- Prix des produits de consommation courante comme les vêtements, les produits alimentaires et les boissons.
- Coûts des services tels que les restaurants, les transports et les divertissements.
- Salaires moyens.
- Prix des billets de cinéma et des abonnements mensuels aux clubs de fitness, entre autres.

Le fichier `world_population.csv` contient des données démographiques plus générales sur les pays, telles que la population mondiale, la densité de population, le nombre de migrants, le taux de fertilité, l'âge médian et la part urbaine de la population. Ces données offrent une vue d'ensemble des tendances démographiques à l'échelle mondiale, mettant en évidence les variations de population, les taux de croissance et d'autres indicateurs clés pour chaque pays.

- Le nom du pays concerné.
- La population totale en 2024.
- La variation annuelle de la population.
- La différence nette entre les arrivées et les départs dans le pays.
- La densité de population.
- La superficie terrestre en Km^2 .
- Le nombre total de migrants.
- Le taux de fertilité.
- Âge médian.
- Population urbaine en
- La part de la population mondiale représentée par le pays en

Le fichier `tourism.csv` contient des données sur le tourisme pour différents pays. Ces données fournissent des informations sur le nombre de touristes visitant chaque pays ainsi que l'année correspondante.

- Le nom du pays concerné.
- Le nombre total de touristes visitant le pays.
- L'année à laquelle les données de tourisme correspondent.

Le fichier `worldcities.csv` contient plus que 47000 lignes de données sur les villes du monde, notamment leur population.

- Le nom de la ville.
- La latitude et la longitude de la ville.
- Le type de capitale (primaire, administrative, etc.).
- La population de la ville.

1.5 Processus de nettoyage et de prétraitement des données

Le processus de nettoyage et de prétraitement des données est effectué dans le fichier `2_clean.ipynb`. Ce fichier comprend les étapes suivantes :

1. **Formatage des données** : Ce processus consiste à formater les données pour garantir leur cohérence et faciliter leur manipulation ultérieure. Il est réalisé en exécutant la fonction `formatting` sur les fichiers contenant les données des hôtels et des régions géographiques.
2. **Correction des valeurs de distance du centre** : Cette étape vise à corriger les valeurs de distance du centre qui dépassent 30 km en les divisant par 1000. Cela est effectué en exécutant la fonction `correct_distance_columns` sur les fichiers concernés.
3. **Suppression des valeurs nulles, des doublons et des valeurs incohérentes** : Cette étape implique la suppression des valeurs nulles, la correction des valeurs incohérentes et la suppression des lignes en double. Elle est réalisée en exécutant différentes fonctions telles que `generate_global_df`, `tourism_join`, et `correct_distance_columns` sur les fichiers appropriés.
4. **Création et nettoyage du fichier `worldcities.csv`** : Cette étape consiste à nettoyer et à formater le fichier `worldcities.csv` pour qu'il soit prêt à être utilisé dans l'analyse des données. Elle est réalisée en exécutant différentes opérations de nettoyage et de prétraitement sur ce fichier.
5. **Fusion des fichiers `worldcities` et `cities`** : Cette dernière étape implique la fusion des données des fichiers `cities.csv` et `worldcities.csv` pour créer un fichier final contenant toutes les informations nécessaires sur les villes. Elle est réalisée en exécutant la fonction `merge` sur ces fichiers.

Analyses et visualisation de données

Ce chapitre marque une étape cruciale de notre étude, où nous plongeons dans une analyse minutieuse des données collectées. Notre objectif est d’explorer en profondeur la distribution des données et d’étudier les relations entre les différentes variables. En examinant de près ces relations, nous cherchons à saisir pleinement le comportement des données et les interactions qui les sous-tendent.

2.1 Description de l’ensemble des données

Dans notre processus d’analyse de données, nous avons consolidé plusieurs ensembles de données pour former une vue globale et cohérente de notre sujet d’étude. Pour faciliter cette consolidation, nous avons développé une fonction dans le fichier `tools.py` qui génère un Data-Frame global en fusionnant les données des pays et des villes avec celles des hôtels disponibles dans le répertoire `/links` et des chambres dans le répertoire `/data`. Nous présentons dans la figure 2.1 un aperçu des résultats agrégés à chaque niveau de notre analyse :

- Niveau 1 : Agrégation des données au niveau des pays.
- Niveau 2 : Agrégation des données au niveau des villes.
- Niveau 3 : Agrégation des données des hôtels comme le score, les évaluations, le nombre d’avis, la distance du centre-ville et le nombre d’étoiles.
- Niveau 4 : Agrégation des données des chambres d’hôtels par type de chambre comprenant le type de chambre, son prix, la politique d’annulation, la disponibilité du petit déjeuner et éventuellement son prix et la capacité de la chambre.




FIGURE 2.1 – L’hiérarchie des données




FIGURE 2.2 – Les 104 pays impliqués dans l'étude

Par la suite, nous utiliserons la fonction `df.describe()` pour obtenir des statistiques descriptives sur chaque ensemble de données agrégées, que nous afficherons de manière élégante en LaTeX.

	Score	NbReviews	...	net_change	land_area	Tourism
min	1.000000	1.000000	...	-2.957105e+06	5.000000e+01	2.900000e+04
max	10.000000	31771.000000	...	1.145449e+07	1.637687e+07	1.171090e+08
mean	8.273027	2337.214490	...	1.086487e+06	3.576082e+06	2.479014e+07
std	0.671158	2804.532294	...	2.364938e+06	4.241905e+06	2.278704e+07

TABLE 2.1 – La description des variables numériques

Le tableau 2.1 présente un résumé statistique des données représentées au niveau 4 (par chambre d'hôtel). Il fournit des statistiques telles que la moyenne, l'écart-type, le minimum et le maximum pour chaque variable. Cela permet d'avoir une vue d'ensemble des caractéristiques des données et de détecter d'éventuelles valeurs aberrantes ou tendances intéressantes.

2.2 Distribution des données

Dans cette section, nous explorerons la distribution de nos données à l'aide des bibliothèques `seaborn`, `matplotlib` et `geopandas`.

2.2.1 Les pays étudiés

Dans notre ensemble de données, nous répertorions un total de 104 pays que nous afficherons avec `geopandas` dans la figure 2.2.




FIGURE 2.3 – Répartition des hôtels étudiés par continent

2.2.2 Répartition des pays étudiés par continent

Nous présentons ici la distribution des hôtels par continent à l'aide de graphiques en camembert de `matplotlib`. La répartition des hôtels (à gauche) et des chambres d'hôtels (à droite) est illustrée. Les deux graphiques, dans la figure 2.3, sont remarquablement similaires, suggérant que le passage du niveau 3 au niveau 4 n'affecte pas significativement la distribution des données. Il est également notable que la majorité des hôtels étudiés se trouvent en Europe ou en Amérique du Nord.

2.2.3 Distribution du score, du nombre d'étoiles et de la distance par rapport au centre-ville

La figure 2.4 illustre la distribution de la distance entre les hôtels et le centre-ville. Cette distribution décroît, notamment en Europe (même en pourcentages), ce phénomène s'explique par l'urbanisme spécifique des villes européennes ainsi que par la densité élevée d'hôtels en Europe.

La figure 2.5 illustre la distribution du nombre d'étoiles (à gauche) et de la capacité des chambres (à droite). Nous observons que la majorité des hôtels étudiés ont une classification en étoiles, à partir de 3 étoiles. De plus, la majorité des chambres étudiées sont de type double, tandis que le reste est réparti entre les chambres simples et triples, avec une minorité de chambres pouvant accueillir 4 invités ou plus.

2.2.4 Distribution du type d'annulation et des services de petit-déjeuner proposés

Dans cette section, nous examinons la distribution des services de petit-déjeuner et des politiques d'annulation offerts par les hôtels, en analysant les données continent par continent.

La figure 2.6 présente deux diagrammes en camembert illustrant la répartition des services de




FIGURE 2.4 – La distribution de la distance du center-ville.




FIGURE 2.5 – La distribution du nombre d'étoiles et de la capacité des chambres




FIGURE 2.6 – La répartition des services de petit-déjeuner et des politiques d'annulation.




FIGURE 2.7 – La répartition des services de petit-déjeuner par continent.




FIGURE 2.8 – La répartition des politiques d’annulation par continent.

petit-déjeuner et des politiques d’annulation parmi les hôtels étudiés. À gauche, nous constatons que 81% des hôtels proposent un petit-déjeuner inclus dans leur offre, 18% ne le proposent pas et le reste offre des options payantes. À droite, 70% des hôtels offrent une politique d’annulation gratuite, tandis que 30% proposent des réservations non remboursables.

La figure 2.7 présente des histogrammes montrant la répartition des services de petit-déjeuner par continent. L’Océanie affiche le pourcentage le plus bas de petit-déjeuner offert (41,49%), tandis que l’Afrique arrive en tête avec le pourcentage le plus élevé (67,92%). Le petit-déjeuner payant est plus fréquent en Amérique (31,46%) et moins courant en Afrique (24,26%). Dans tous les continents, la majorité des hôtels proposent le petit-déjeuner (plus de 40% dans chaque continent).

La figure 2.8 présente des histogrammes montrant la répartition des politiques d’annulation par continent. La tendance générale est similaire dans chaque continent, avec une forte prévalence des politiques d’annulation gratuites. Cependant, il existe des variations subtiles entre les continents, comme une proportion légèrement plus élevée d’hôtels avec des politiques d’annulation non remboursables en Europe par rapport aux autres continents. Globalement, les politiques d’annulation gratuites dominent dans tous les continents, indiquant une tendance générale vers la flexibilité des réservations dans l’industrie hôtelière (voir figure 2.8).




FIGURE 2.9 – Le prix moyen et le score moyen des hôtels par pays.

2.3 Les relations entre les variables

Nous souhaitons étudier comment les caractéristiques de la ville influent sur les caractéristiques de l'hôtel. Cette approche vise à mieux comprendre la dynamique complexe entre l'environnement urbain et l'industrie hôtelière. En effet, divers aspects de la ville, tels que le coût de la vie, la démographie et les attractions touristiques locales peuvent avoir un impact significatif sur le fonctionnement et les offres des hôtels. Par exemple, dans des villes où le coût de la vie est élevé, les hôtels peuvent adapter leurs tarifs et leurs services en conséquence pour rester compétitifs sur le marché. De même, les destinations touristiques populaires peuvent entraîner une demande accrue d'hébergement, influençant ainsi les politiques d'annulation et les prix des chambres. En analysant ces relations complexes, nous visons à identifier les facteurs clés qui influencent les performances et les stratégies des hôtels, fournissant ainsi des insights précieux pour les gestionnaires d'hôtels et les décideurs urbains.

2.3.1 Relation entre le prix et le score

La figure 2.9 présente le prix moyen des hôtels pour chaque pays, avec des teintes sombres indiquant des prix élevés et des teintes claires correspondant à des prix plus bas. Les scores moyens sont représentés par des bulles rouges, avec un diamètre plus important indiquant un score plus élevé. Pour améliorer la lisibilité de la visualisation, des transformations telles que la transformation logarithmique du prix et l'exponentiation, ainsi que la normalisation du score ont été appliquées. Nous observons une tendance selon laquelle les pays affichant les scores les plus élevés sont souvent ceux proposant des prix plus bas, suggérant ainsi que les clients attribuent généralement de meilleures évaluations aux hôtels offrant des tarifs plus avantageux.




FIGURE 2.10 – Nombre de pays en commun entre les k pays ayant les scores les plus élevés et les k pays ayant les prix moyens les plus élevés ou les plus bas.

Une manière de confirmer cette hypothèse consiste à examiner le nombre de pays en commun entre les k premiers pays de la liste triée par prix moyen et les k premiers pays de la liste triée par score moyen. Les résultats sont présentés dans la figure 2.10, où il est clairement visible que la courbe rouge est presque toujours au-dessus de la courbe bleue.

2.3.2 Relation entre la distance du centre-ville et le score

Nous avons entrepris une analyse approfondie pour évaluer l'impact de la distance des hôtels par rapport au centre-ville sur leur score de satisfaction. Pour ce faire, nous avons segmenté nos données en trois catégories distinctes : proche, moyen et éloigné. Chaque catégorie représente environ 33 % de l'ensemble de nos données, permettant une répartition équitable des observations. Cette méthodologie nous permettra de mieux comprendre comment la distance influe sur la perception globale des hôtels par les clients, telle que mesurée par le score de satisfaction. Nous avons procédé à la visualisation de la distribution des scores dans chaque catégorie, comme illustré dans les figures 2.11 et 2.12.

Voici les résultats obtenus :

- Moyenne des scores pour les hôtels proches : 8.28
- Moyenne des scores pour les hôtels à distance moyenne : 8.29
- Moyenne des scores pour les hôtels éloignés : 8.24

Nous allons maintenant effectuer des tests statistiques pour déterminer s'il existe des différences significatives entre ces catégories en termes de moyennes de scores.

Tout d'abord, nous avons établi que les données étaient indépendantes les unes des autres. Ensuite, pour déterminer si les variances étaient homogènes entre les groupes, nous avons effectué le test de Bartlett, donnant les résultats suivants :




FIGURE 2.11 – Distribution des distances par catégorie




FIGURE 2.12 – Boîte à moustaches des scores par distance

— Statistique de test de Bartlett : 5.267

— Valeur p : 0.0718

La valeur p étant supérieure à 0.05, nous pouvons conclure que les variances des données sont homogènes.

Par la suite, nous avons utilisé le test de Shapiro-Wilk pour vérifier si chaque catégorie suivait une distribution normale :

— Valeur p pour la catégorie "Éloigné" : 6.63×10^{-33}

— Valeur p pour la catégorie "Moyen" : 3.80×10^{-31}

— Valeur p pour la catégorie "Proche" : 8.34×10^{-30}

Ces résultats montrent que les données ne suivent pas une distribution normale. Par conséquent, nous ne pouvons pas utiliser le test ANOVA.

Nous avons alors eu recours au test de Kruskal-Wallis, une alternative non paramétrique à l'ANOVA à un facteur, qui ne repose pas sur des hypothèses de normalité. Les conditions nécessaires pour appliquer ce test étaient réunies (indépendance, homogénéité, données continues, taille d'échantillon suffisante). Nous avons obtenu les résultats suivants :

— Statistique de test de Kruskal-Wallis : 7.901

— Valeur p : 0.0192

Ces résultats indiquent qu'il existe suffisamment de preuves pour conclure qu'il y a des différences significatives entre les groupes (Valeur $p < 0.05$).

2.3.3 La corrélation

Nous classerons nos variables en deux catégories distinctes : les variables concernant les hôtels et leurs offres d'hébergement (H_{var}) et les variables environnementales (telles que les données sur la ville, le coût de la vie dans la ville, les données démographiques générales, etc.) (E_{var}). Nous présenterons ensuite la matrice de corrélation (en valeur absolue) entre les variables de E_{var} (en colonnes) et celles de H_{var} (en lignes).




FIGURE 2.13 – Corrélation entre les variables des hôtels et leur environnement.

Les variables les plus fortement corrélées sont *Nb_reviews*, *value_for_money_rating* et *Score*. Toutefois, les valeurs de corrélation ne dépassent pas 0.4, indiquant l'absence de corrélation directe entre ces variables.

La tableau 2.2 illustre les paires de variables d'hôtels et de variables environnementales les plus corrélées, avec une corrélation maximale de bornée par 0.34. Cette corrélation indique une relation linéaire modérée à faible entre ces variables.

TABLE 2.2 – Les paires de variables d’hôtels et de variables environnementales les plus corrélées.

H_{var}	E_{var}	Correlation
NbReviews	1 Pair of Jeans (Levis 501 Or Similar)	0.331068
Distance from center	Gasoline (1 liter)	-0.305853
NbReviews	Gasoline (1 liter)	0.303843
Value_for_money_rating	Apartment (1 bedroom) in City Centre	-0.294301
Value_for_money_rating	Apartment (1 bedroom) Outside of Centre	-0.291199
NbReviews	Taxi 1km (Normal Tariff)	0.289978
Value_for_money_rating	Cigarettes 20 Pack (Marlboro)	-0.288145
Guests nb	land_area	0.282094
Value_for_money_rating	Average Monthly Net Salary (After Tax)	-0.278141
Guests nb	migrants	0.266503
Value_for_money_rating	Imported Beer (0.33 liter bottle)	-0.257083




FIGURE 2.14 – Analyse en Composantes Principales pour les deux catégories de variables

2.4 Analyse en Composantes Principales

Pour prédire avec précision le score moyen des hôtels pour chaque ville, il est nécessaire d'utiliser un grand nombre de variables, ce qui peut rendre l'analyse complexe et exigeante en termes de ressources. C'est pourquoi nous avons opté pour l'utilisation de l'Analyse en Composantes Principales (ACP), comme illustré dans la figure 2.14.

Nous avons appliqué l'ACP indépendamment aux variables des hôtels H_{var} et aux variables de l'environnement E_{var} (gauche). Pour H_{var} , l'analyse capture près de 99% de la variance totale des données avec seulement deux composantes principales (droite). Pour E_{var} , la première composante principale capture également 99% de la variance totale. Cela indique que ces composantes principales contiennent une quantité significative d'informations pertinentes pour la conception de nos modèles.

Modèles de prédiction

Ce chapitre vise à mettre en œuvre des modèles permettant de prédire une propriété (une variable) des environnements des hôtels *Evar* en se basant sur les valeurs des caractéristiques des hôtels *Hvar*, et vice versa. Nous avons mené deux types de prédictions s : d’une part, une prédiction des hôtels (au niveau 3 d’agrégation, voir 2.1) et, d’autre part, une prédiction des offres de chambres (au niveau 4 d’agrégation), en utilisant les mêmes critères de prédiction pour les deux cas. La différence fondamentale entre ces deux approches réside dans le niveau de granularité des données considérées : lors de la classification des hôtels, chaque établissement est traité comme une entité unique, tandis que lors de la classification des chambres, chaque offre d’hébergement dans chaque hôtel est considérée comme une observation distincte.

3.1 Prédiction du score à partir des variables des villes

Dans cette analyse, notre objectif était de prédire le score moyen des hôtels en se basant sur les caractéristiques spécifiques à chaque ville présentant la corrélation la plus forte avec le score global. Les modèles sont entraînés sur les composantes principales ayant assez d’information sur la variance (voir 2.4), donc pour lancer des tests, il faut faire une projection des données sur les axes des composantes considérées. Pour cela, nous avons exploré deux modèles de régression : la régression linéaire et le modèle RandomForestRegressor sur les deux niveaux d’agrégation (hôtels et chambres d’hôtels).

Modèle	Niveau d’agrégation	R ² Score	MSE
Régression Linéaire (RL)	Hôtels	0.0150	0.4371
	Chambres d’hôtels	0.3876	0.0565
Random Forest Regressor (RFR)	Hôtels	0.7424	0.1143
	Chambres d’hôtels	0.4431	0.0514

TABLE 3.1 – Comparaison des performances des modèles de régression linéaire et de Random Forest Regressor sur différents niveaux d’agrégation des données. Les meilleurs résultats sont en gras.

Les résultats indiquent que le modèle RandomForestRegressor a surpassé la régression linéaire en termes de précision prédictive pour les deux niveaux d’agrégation. En particulier, le modèle RandomForestRegressor a produit une erreur quadratique moyenne (MSE) plus faible et un R² score plus élevé pour le niveau des hôtels, indiquant une meilleure capture de la relation entre les caractéristiques des villes et les scores moyens des hôtels. Pour le niveau des chambres d’hôtels, bien que le R² score ne soit pas disponible, le MSE plus faible du Random Forest Regressor suggère également une performance supérieure.

3.2 Prédiction du continent à partir des variables des hôtels

Nous cherchons à effectuer une classification des hôtels (en utilisant les informations liées aux hôtels suivantes : ['Stars', 'Score', 'Staff_rating', 'Distance from center', 'Facilities_rating', 'Cleanliness_rating', 'Comfort_rating', 'Value_for_money_rating', 'Location_rating', 'Price']) et des chambres d'hôtels (en utilisant les mêmes informations mais à un niveau d'agrégation plus détaillé) par leur continent d'appartenance. Les résultats sont représentés dans le tableau 3.2.

Niveau d'agrégation	Cible	Nombre d'entités	Modèle	Accuracy
Hôtels	Hôtels	7690	KNeighborsClassifier	0.3315
			RandomForestClassifier	0.4115
	Chambres d'hôtels	155019	KNeighborsClassifier	0.8103
			RandomForestClassifier	0.9961

TABLE 3.2 – Résultats de la classification des hôtels et des chambres d'hôtels par continent

Les résultats montrent que la précision de la classification s'améliore significativement lorsque les chambres individuelles sont prises en compte plutôt que les hôtels dans leur ensemble. En particulier, le modèle RandomForestClassifier appliqué aux chambres d'hôtels atteint une précision de **99,61%**, ce qui est le meilleur résultat parmi les modèles testés. Voici quelques raisons possibles de cette amélioration :

- **Augmentation de la taille de l'échantillon** : La classification des chambres individuelles augmente considérablement la taille de l'échantillon, or les résultats montrent une amélioration de la précision de classification lorsque les chambres individuelles sont considérées plutôt que les hôtels dans leur ensemble. Plusieurs raisons peuvent expliquer cette différence de précision :
 - **Augmentation de la taille de l'échantillon** : La classification des chambres individuelles augmente considérablement la taille de l'échantillon, offrant au classificateur plus de données pour l'apprentissage, ce qui peut conduire à une meilleure précision.
 - **Meilleure représentation des caractéristiques de l'hôtel** : En prenant en compte plusieurs chambres au sein d'un hôtel, le classificateur obtient une représentation plus détaillée des caractéristiques de cet hôtel, facilitant ainsi la distinction entre les hôtels de différentes régions en fonction de leurs caractéristiques et équipements uniques.
 - **Réduction du déséquilibre des classes** : En cas de déséquilibres dans la distribution des hôtels entre les régions, la classification des chambres individuelles




FIGURE 3.1 – La matrice de confusion du classifieur de régions.

permet d’obtenir une distribution plus équilibrée des points de données entre les classes, améliorant ainsi la capacité du classificateur à apprendre les caractéristiques distinctives de chaque région.

En résumé, la classification des chambres individuelles, en multipliant les données disponibles et en offrant une meilleure représentation des caractéristiques des hôtels, peut conduire à une amélioration de la précision de la classification.

3.3 Prédiction de la région à partir des variables des hôtels

Dans cette partie, nous poursuivons notre analyse en nous concentrant sur la prédiction de la région. L’objectif est d’obtenir une meilleure précision géographique en classifiant les données par région et en faisant la prédiction toujours avec les mêmes variables. Contrairement au modèle précédent, nous utilisons uniquement les données des chambres d’hôtels, comme indiqué dans la section 3.2. Les résultats obtenus sont présentés dans le tableau 3.3 :

Cible	Modèle	Accuracy
Chambres d’hôtels	KNeighborsClassifier	0.6889
	RandomForestClassifier	0.9890

TABLE 3.3 – Résultats de la classification des chambres d’hôtels par région

Les résultats montrent que le modèle `RandomForestClassifier` obtient une précision remarquable de **98,90%**, ce qui suggère qu’il est très performant pour prédire la région à laquelle appartient une chambre d’hôtel. En revanche, le modèle `KNeighborsClassifier` affiche une précision moins élevée de 68,89%. La matrice de confusion est dans la figure 3.1.




FIGURE 3.2 – La matrice de confusion de la classification par pays.




FIGURE 3.3 – La matrice de confusion de la classification par ville.

Il est important de noter que ces résultats sont basés sur les données spécifiques que nous avons utilisées dans notre analyse. Des améliorations supplémentaires pourraient être apportées en utilisant un ensemble de données plus complet ou en ajustant les paramètres des modèles.

3.4 Prédiction du pays et la ville d'un hôtel

Les mêmes méthodes ont été appliquées sur les mêmes données mais en modifiant le niveau de précision géographique. Le classificateur Random Forest a prédit le pays en se basant sur les mêmes caractéristiques comme fait précédemment avec une accuracy de **0,9888** et la ville avec une accuracy de **0,9976**. Les matrices de confusions normalisées des deux prédictions sont dans les figures 3.2 et 3.3 respectivement.

Tableau de bord

Nous avons créé un tableau de bord interactif à l'aide de la bibliothèque **Dash**, permettant une exploration interactive des données de l'industrie hôtelière.

Notre démarche a débuté par l'importation des données depuis un fichier **CSV** et leur préparation pour l'analyse. Nous avons utilisé **Pandas** pour effectuer diverses opérations, telles que la sélection de colonnes pertinentes pour notre analyse, le regroupement des données par ville, pays et continent, ainsi que la fusion de plusieurs jeux de données pour obtenir une vue d'ensemble de l'industrie hôtelière.

Ensuite, nous avons utilisé **Seaborn** pour créer une visualisation initiale : un histogramme montrant la distribution des scores des hôtels par continent. Cette visualisation nous a fourni une première idée de la répartition des scores dans différentes régions du monde. Par la suite, nous avons converti cette visualisation **Seaborn** en une figure **Plotly**, offrant une interactivité supplémentaire. Nous avons ajusté la taille de la figure et ajouté un titre pour la rendre visuellement plus attrayante.

Parallèlement, nous avons commencé à construire notre tableau de bord avec **Dash**. Nous avons utilisé plusieurs composants **Dash**, tels que des colonnes, des rangées, des graphiques, des boutons radio et des listes déroulantes, pour créer une interface utilisateur intuitive et interactive.

Nous avons inclus plusieurs graphiques dans notre tableau de bord, chacun représentant différentes informations sur l'industrie hôtelière. Par exemple, nous avons ajouté des graphiques à secteurs pour visualiser la répartition des types de petit-déjeuner et des politiques d'annulation des hôtels. Nous avons également inclus des histogrammes pour analyser la distribution des scores, des étoiles et d'autres caractéristiques des hôtels, en les segmentant par continent.

Pour rendre notre tableau de bord encore plus dynamique, nous avons utilisé des **callbacks** pour mettre à jour les graphiques en fonction des sélections de l'utilisateur. Par exemple, lorsqu'un utilisateur sélectionne un continent dans une liste déroulante, les graphiques se mettent à jour pour afficher les données spécifiques à ce continent.

En résumé, notre tableau de bord **Dash** offre une plateforme interactive pour explorer et analyser les données de l'industrie hôtelière, permettant aux utilisateurs de visualiser aisément les tendances et les variations dans les scores, les étoiles, les services et les politiques des hôtels à travers le monde. En exécutant le fichier `app.py`, on trouve un tableau de bord comme illustré dans les figures 4.1, 4.2 et 4.3.

1.Hotels Features




FIGURE 4.1 – Dashboard - Partie 1




FIGURE 4.2 – Dashboard - Partie 2




FIGURE 4.3 – Dashboard - Partie 2

Conclusion

Après avoir mené à bien ce projet de collecte et de construction d'une vaste base de données sur les hôtels de **Booking.com** et d'autres sites, nous avons réalisé plusieurs analyses significatives. Tout d'abord, nous avons étudié en détail la relation entre le score des hôtels et leurs prix, ce qui nous a permis de mieux comprendre les tendances du marché. Ensuite, nous avons développé un tableau de bord interactif pour présenter ces informations de manière accessible au grand public.

En outre, nous avons créé des modèles de prédiction du score des hôtels en nous basant sur les informations de la ville, ce qui nous a permis de fournir des estimations précises du score des hôtels à partir de données contextuelles grâce à **Random Forest Regressor** qui donne un **r2-score=0.74**. Enfin, nous avons réalisé une classification des hôtels par continent, région, pays ou ville avec le modèle **Random Forest Classifier**, ce qui nous a permis d'obtenir une meilleure précision géographique dans notre analyse de **99%**.

Dans l'ensemble, ce projet a été une réussite, nous avons non seulement accompli nos objectifs initiaux, mais nous avons également acquis de précieuses connaissances sur le marché des hôtels et sur les méthodes d'analyse de données dans le domaine du tourisme et de l'hôtellerie. Ces résultats pourraient être utilisés pour prendre des décisions commerciales éclairées et pour mieux comprendre les besoins des clients dans ce secteur.

Vous pouvez consulter le code source de notre projet sur GitHub via le lien en bas de page.¹.

1. <https://github.com/chettabyacine/M1-S2-DALAS>